

我判断创新点的标准

四条：① 有没有论文支撑（不是自嗨）；② 和这个评测器机制适配（能不能转化成分数）；③ 在"10 轮、50k 目录、可离线"约束下做不做得出；④ 评审 (Innovation 20% + Feasibility 15%) 看不看得懂。

创新方向判断（按优先级）

1 A. 熵驱动的提问选择（信息增益提问）——强推

论文依据：

- [Entropy Guided Diversification and Preference Elicitation in Agentic Recommendation Systems](#) (2026, IDSS) ——直接给你公式：对当前候选集 C，每个属性维度 d 算香农熵 $H(d) = -\sum p(v)\log_2 p(v)$ ，再归一化 $H_{\text{norm}} = H(d)/\log_2 |\text{Val}(d)|$ ，然后选 $d^* = \text{argmax } H(d)$ ，并设熵阈值 $\tau=0.3$ ，低于阈值就停止提问直接推荐；
- [Asking Clarifying Questions in Open-Domain Information-Seeking Conversations](#) (Aliannejadi, SIGIR 2019) ——澄清问题研究的开山之作；
- 你清单里已有的 [EAR \(WSDM 2020\)](#) ——提问 vs 推荐策略的经典框架。

怎么落地到这个比赛：维护当前候选池（按已披露约束过滤后），对每个没问过的属性统计候选池里的取值分布（材质、颜色、价格分桶、风格关键词……），问熵最高的属性；再加一个"覆盖率"修正——优先问目标大概率有值的属性（目录里常见的属性），避免问出一个"我没有额外偏好"的废轮。

我的判断：实现成本低（纯统计，无训练）、直接吃中 Hit 和 MTTC、论文背书完整，是性价比最高的创新点，而且能讲清楚。

1 B. "何时问、何时停"的不确定性早停——强推

论文依据：

- IDSS 同篇的"最低熵阈值 $\tau_H \rightarrow$ 直接进入推荐"；
- [UNICORN: Unified Conversational Recommendation Policy Learning via Graph-based RL](#) ——把"when to ask vs recommend"作为统一决策问题；
- 综述论文里也专门讨论过"when to ask and recommend"（你已读的第 5 节）。

怎么落地：每轮都照推 top-10（评测器每轮检查），但"是否继续问"由候选池熵决定：熵高 $\rightarrow$ 问；熵低于阈值或已问完高价值属性 $\rightarrow$ 停止提问，只推。这个"该问才问"的决策本身就是你的核心创新故事，同时天然保护 MTTC。

我的判断：强推。注意别抄 UNICORN 的 RL——200 条会话不足以训策略，用 IDSS 式的确定性阈值更稳。

1 C. 意图覆盖检测 + 槽位重置——强推（15% 场景的胜负手）

论文依据：

- [Interpretable and Robust Dialogue State Tracking via Natural Language Summarization with LLMs](#) ——用 LLM 维护对话状态、处理噪声；
- [CoCo: Controllable Counterfactuals for Evaluating Dialogue State Trackers](#) (ICLR 2021) ——专门用"用户改口"这种反事实测 DST 鲁棒性，和 Intent Override 场景一模一样；
- IDSS 的语义解析器也明确做了"newer values override previous ones"。

怎么落地：给每个槽位记录"值 + 来源轮次"。当新消息和旧槽位冲突（规则检测或 LLM 判断），把冲突槽位清空重填，候选池按新约束重建，旧约束降权而不是删除（用户可能只改一个维度）。

我的判断：实现成本中等，但这是 15% 私有会话的专属考题，而且"覆盖感知的状态管理"是评审容易记住的亮点。

2 D. 混合检索 + LLM 两阶段精排——必做，但不算创新故事

论文依据：

- [Large Language Models are Zero-Shot Rankers \(RankGPT\)](#) + [RankVicuna](#)——listwise LLM 重排；
- Amazon 自己的产品搜索实践：[Improving Relevance Quality in Product Search using High-Precision Query-Product Semantic Similarity](#) (BERT 交叉编码器重排) 和 [KDD Cup 2022 冠军方案](#) (粗排 → 交叉编码器精排)；
- [Hint-Augmented Re-ranking: LLM-Based Query Decomposition for Product Search](#)——LLM 查询拆解 + 重排。

怎么落地：BM25 + 类别过滤 + 稠密检索 → 粗排 100 → LLM listwise 精排 top-10 (或本地交叉编码器兜底)。注意：评测器只认目录内有效 ASIN，必须检索不能生成。

我的判断：这是提分的工程地基 (35% Technical Execution 靠它)，但单独做它没有 Innovation 分——把它和 A/B/C 组合起来讲故事才有价值。

2 E. 画像先验个性化——推荐，低成本

论文依据：[Shopping Companion: Benchmarking and Training LLM Agents for Long-Horizon Preference-Grounded E-Commerce Tasks](#) (2026)

——"preference-grounded"任务正是你拿到的匿名画像 (preference_tags + summary) 该用的方式；还有 [Shopping MMLU](#) (NeurIPS 2024) 里对购物多技能的定义。

怎么落地：preference_tags (fit/comfort/material...) 转成精排加权；summary 生成画像先验提示词。Browsing 场景 (40%) 没有硬约束，画像先验是早期命中的主要武器。

我的判断：推荐，成本低，对 Browsing 和 Boundary 都有帮助。

3 F. 透明解释 + 失败检测 / 策略切换——可选加分项

论文依据：[ProductAgent: Benchmarking Conversational Product Search Agent with Asking Clarification Questions](#) (EMNLP 2025 Industry)——LLM + 领域工具、结构化记忆、候选特征统计摘要、混合检索闭环，是你整个 agent 架构最接近的参考；失败检测对应你读过的综述里"对话崩溃修复"。

怎么落地：连续两轮提问后候选池熵不下降 → 判定提问无效，切换为"画像先验 + 热门商品"兜底；解释用 LLM 给 top-3 各生成一句理由 (不参与评分，但评审观感好)。

我的判断：最后做。ProductAgent 这篇建议读全文——它几乎是这个比赛的"参考答案架构"。

不建议做的

- RL 策略学习 (UNICORN/EAR 路线)：200 条会话训不出策略，且调参成本爆炸，用确定性阈值即可；
- 微调基础模型：规则明确 out of scope；
- 生成式检索 (让 LLM 直接吐商品名)：评测器只认精确 ASIN 匹配，必须检索；
- 多模态 / 外部向量库：out of scope。

一页纸创新故事 (Devpost 直接用)

Uncertainty-Aware Conversational Shopping Agent (基于不确定性的对话式购物 Agent)

核心主张：把"熵"作为贯穿全流程的统一信号——用候选池的熵决定问什么 (信息增益最高的属性)、用熵的下降决定何时停问 (不确定性早停)、用槽位的覆盖检测处理用户改口 (意图覆盖重置)。检索端用混合检索 + LLM 精排，本地优先保证可离线运行。和论文的对应：熵驱动提问 (IDSS 2026)、澄清问题 (Aliannejadi 2019)、覆盖感知状态管理 (CoCo/LLM-DST)、产品检索精排 (Amazon KDD Cup / RankGPT)、产品澄清 Agent (ProductAgent 2025)。

这个故事的 Innovation 点清晰、有论文谱系、且每个组件都能在 demo 里展示出来——评审最容易买账。

落地顺序

1. 先把 D (混合检索 + 精排) 做扎实——它是所有分数的地基；
2. 加 A + B (熵提问 + 早停)——主创新点，改一个函数就能测；
3. 加 C (覆盖重置)——吃掉 15% 场景；
4. 加 E (画像先验) → 最后 F (解释 + 失败检测)；
5. 每一步跑全量 200 条记录三指标，写进消融表。